Proyectos reproducibles de ciencia de datos

Un marco práctico para docentes

Tabla de contenidos

1 Introducción **2**
- 1.1 Dos dimensiones complementarias de la reproducibilidad . . . 2
- 1.2 Investigación reproducible y comunicación científica . . . 3
- 1.3 Relación con CRISP-DM . . . 4

2 Organización de un proyecto de investigación reproducible **4**
- 2.1 El repositorio como unidad de reproducibilidad . . . 4
- 2.2 Una estructura mínima de directorios . . . 5
- 2.3 Archivos fuente y productos generados . . . 6
- 2.4 Nombres y rutas . . . 7

3 Cuadernos computacionales **7**
- 3.1 El papel de los cuadernos Quarto . . . 7
- 3.2 Programación literaria y el "cómo" computacional . . . 7
- 3.3 Una responsabilidad analítica por cuaderno . . . 8
- 3.4 Una estructura estándar para los cuadernos . . . 8
- 3.5 Ejecución independiente y dependencias explícitas . . . 8
- 3.6 Transparencia computacional y reproducibilidad . . . 9

4 Informes de investigación y artículos científicos **9**
- 4.1 Los informes de investigación como documentación metodológica . . . 9
- 4.2 Los artículos científicos como comunicación de contribuciones a la investigación 10
- 4.3 Responsabilidades complementarias . . . 10
- 4.4 Relación con los hitos de presentación de informes . . . 11

5 Flujos de trabajo modulares y automatizados **11**
- 5.1 Modularidad analítica y modularidad del software . . . 11
- 5.2 Funciones reutilizables de R y `src/` . . . 12
- 5.3 Scripts ejecutables y `scripts/` . . . 12

5.4 Del análisis interactivo a un flujo de trabajo automatizado 13
5.5 Comprobaciones de reproducibilidad 13

6 Uso educativo del marco **14**
6.1 Responsabilidades docentes y competencias previstas 14
6.2 El marco y su implementación en el aula 14

7 Principios finales **15**

1. Introducción

Un proyecto de investigación en ciencia de datos implica más que aplicar métodos estadísticos a un conjunto de datos. Requiere formular una pregunta significativa, identificar y evaluar información pertinente, preparar los datos para el análisis, interpretar los resultados y comunicar los hallazgos. Un proyecto reproducible permite que otras personas accedan tanto al razonamiento como a los cálculos que sustentan estas actividades.

Esta guía presenta un marco práctico para organizar la investigación reproducible en proyectos de ciencia de datos. Integra la documentación de la investigación, la programación literaria, la gestión del entorno computacional, el control de versiones y la organización modular de proyectos. Su objetivo es hacer comprensibles las decisiones de investigación, reproducibles los resultados computacionales y más sencilla la continuidad de las investigaciones cuando cambia el personal investigador.

El público inmediato son los docentes que coordinan cursos de ciencia de datos orientados a la investigación. La guía explica los fundamentos del marco y las responsabilidades de sus componentes; no es un tutorial para estudiantes ni una secuencia prescrita de tareas. Otras instrucciones dirigidas a estudiantes pueden traducir estos principios en actividades concretas. El marco también puede servir de base para investigaciones y publicaciones educativas posteriores, pero su propósito inmediato es favorecer una comprensión compartida entre docentes.

1.1. Dos dimensiones complementarias de la reproducibilidad

En esta guía reconocemos dos dimensiones complementarias de la reproducibilidad:

- **Reproducibilidad computacional:** es la capacidad de obtener los mismos resultados computacionales al ejecutar los procedimientos documentados, con los mismos datos de entrada, en un entorno computacional reproducible. Depende de la disponibilidad de los datos, el código, las dependencias, la configuración y las instrucciones de ejecución. Cuando interviene la aleatoriedad, también deben controlarse las semillas y otros parámetros pertinentes. Sin embargo, algunos cálculos pueden seguir variando entre plataformas o versiones del software.

- **Reproducibilidad metodológica:** se refiere a hacer suficientemente explícitos el diseño de la investigación y las decisiones analíticas para que otro investigador pueda comprender, examinar y aplicar los mismos procedimientos. Esto incluye la formulación de las preguntas de investigación, la elección de observaciones y variables, el tratamiento de los datos faltantes, la selección de métodos estadísticos y la interpretación de los resultados. Aquí se utiliza este término como una distinción práctica para organizar el trabajo; la terminología varía entre campos de investigación.

Conviene destacar que estas dimensiones son complementarias, pero ninguna garantiza la otra. Un script puede reproducir un resultado numérico sin explicar por qué el cálculo era apropiado. A la inversa, puede ser imposible reproducir computacionalmente un informe cuidadosamente justificado si su código o sus datos no están disponibles.

Dimensión	Pregunta orientadora	Evidencia principal
Reproducibilidad computacional	¿Se pueden ejecutar de nuevo los cálculos?	Datos, código ejecutable, dependencias, configuración, instrucciones
Reproducibilidad metodológica	¿Se pueden comprender y evaluar las decisiones de investigación?	Preguntas, supuestos, criterios de decisión, justificaciones, limitaciones

La reproducibilidad es distinta de la *replicación*, que comúnmente se refiere a investigar si un resultado puede obtenerse de nuevo utilizando datos nuevos o mediante un estudio realizado de forma independiente. El uso de estos términos difiere entre disciplinas.

1.2. Investigación reproducible y comunicación científica

La *investigación reproducible* es el objetivo general de este marco. Las dimensiones computacional y metodológica anteriores se refieren a la posibilidad de reconstruir y examinar el trabajo. La comunicación científica cumple un propósito relacionado, pero distinto: dar a conocer hallazgos seleccionados y la evidencia que los sustenta a una comunidad de investigación más amplia.

Tres tipos de documentos tienen responsabilidades complementarias:

Producto	Pregunta principal	Propósito principal
Cuaderno computacional	¿*Cómo* se calcularon los resultados?	Explicar y ejecutar procedimientos analíticos
Informe de investigación	¿*Qué* se investigó y *por qué* se tomaron las decisiones?	Preservar el conocimiento metodológico y facilitar la continuidad de la investigación

Producto	Pregunta principal	Propósito principal
Artículo científico	*¿Qué contribución* aportan los hallazgos y *qué evidencia la sustenta*?	Comunicar y fundamentar hallazgos seleccionados en su contexto científico

Estas son distinciones de propósito, no límites excluyentes. Un artículo debe contener suficiente información metodológica para permitir una evaluación independiente y debe cumplir con los estándares aplicables de reproducibilidad y presentación de resultados. Un informe debe identificar la evidencia computacional que respalda sus hallazgos. Un cuaderno debe registrar las decisiones precisas necesarias para ejecutar un análisis, incluso cuando su justificación más amplia se desarrolla en el informe.

La difusión y el escrutinio científicos no deben tratarse como un tercer tipo de reproducibilidad. Asimismo, la reproducibilidad no establece por sí sola la validez científica: un método inapropiado puede ejecutarse con perfecta consistencia.

1.3. Relación con CRISP-DM

El Proceso Estándar Intersectorial para la Minería de Datos (CRISP-DM, por sus siglas en inglés) ofrece una referencia útil para organizar el trabajo en ciencia de datos: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue. Sin embargo, un proyecto de investigación no tiene que seguir literalmente estas fases.

En una investigación académica, los investigadores pueden formular sus propias preguntas en lugar de traducir los objetivos de una organización cliente en tareas analíticas. Los conjuntos de datos disponibles pueden limitar las preguntas que se pueden responder, y la exploración puede motivar revisiones del diseño original de la investigación. Por ello, el enfoque desarrollado aquí está *inspirado en CRISP-DM*, en lugar de ser una implementación estricta de CRISP-DM.

La metodología describe el proceso de investigación; la arquitectura del repositorio describe cómo documentar e implementar ese proceso. No es necesario que sus estructuras sean idénticas. En particular, la organización de los cuadernos computacionales debe reflejar responsabilidades analíticas coherentes, no necesariamente la secuencia de fechas de entrega de informes.

2. Organización de un proyecto de investigación reproducible

2.1. El repositorio como unidad de reproducibilidad

Un solo cuaderno rara vez basta para reproducir una investigación completa. La reproducción también puede requerir conjuntos de datos de entrada, código reutilizable, versiones de paquetes,

archivos de configuración e instrucciones. Por tanto, el *repositorio* es la unidad natural para organizar los materiales reproducibles del proyecto.

El repositorio debe permitir determinar:

1. Qué datos de entrada se utilizaron y de dónde proceden.
2. Qué procedimientos generaron cada resultado analítico.
3. Qué productos se generaron y dónde se encuentran.
4. Qué supuestos y decisiones orientaron el análisis.
5. Cómo puede otra persona ejecutar los cálculos pertinentes.

El control de versiones, habitualmente mediante Git, registra la evolución de los archivos fuente y facilita la colaboración. Un repositorio por sí solo no garantiza la reproducibilidad: los datos externos, los entornos de software, las rutas de archivos y el orden de ejecución también requieren atención.

2.2. Una estructura mínima de directorios

Un proyecto pequeño puede comenzar sin directorios separados para funciones reutilizables o scripts de automatización:

```
project/
|-- README.md
|-- .gitignore
|-- renv.lock
|-- renv/
|   |-- activate.R
|-- data/
|   |-- raw/
|   |-- processed/
|-- notebooks/
|-- quarto/
|   |-- reports/
|   |-- _quarto.yaml
|-- docs/
    |-- reports/
```

Este ejemplo supone un proyecto Quarto cuya raíz está en `project/quarto/`, con `project.output-dir: ../docs`; Quarto generalmente conserva los subdirectorios relativos a los archivos fuente dentro del directorio de salida. Debe comprobarse la ubicación exacta de los archivos de salida para los formatos y la versión de Quarto seleccionados.

Las responsabilidades de los distintos componentes del repositorio se resumen en la siguiente tabla:

Ubicación	Responsabilidad
`README.md`	Explicar el proyecto, los requisitos previos y el procedimiento de reproducción
`quarto/_quarto.yaml`	Configurar la renderización del proyecto Quarto
`data/raw/`	Almacenar los datos de entrada originales, sin modificaciones, cuando se permita su redistribución
`data/processed/`	Almacenar los datos procesados que se utilizarán en el proyecto de investigación
`notebooks/`	Almacenar documentos analíticos ejecutables
`quarto/reports/`	Almacenar los documentos fuente de los informes
`docs/`	Almacenar los productos generados que se pueden distribuir

Más adelante, el proyecto puede incorporar `src/` y `scripts/`. Estos directorios deben introducirse cuando resuelvan un problema real de organización, no simplemente para imitar un proyecto de software de gran tamaño.

2.3. Archivos fuente y productos generados

Los *archivos fuente* son los materiales que editan los investigadores: documentos `.qmd`, código R, configuración y documentación. Los *productos generados* son resultados creados a partir de esas fuentes: informes renderizados en PDF o HTML, figuras, tablas y conjuntos de datos preparados.

Separar las fuentes de los productos generados reduce la ambigüedad. Un informe PDF pertenece a una ubicación destinada a la publicación o distribución; el documento `.qmd` que lo genera pertenece a los materiales fuente editables del proyecto. Cuando sea viable, los productos generados deben poder reproducirse a partir de las fuentes registradas en el control de versiones, en lugar de modificarse manualmente después de la renderización.

No es necesario incluir todos los archivos generados en el control de versiones de Git. La decisión depende de si el archivo es un entregable requerido, de la facilidad con que puede regenerarse, de su tamaño y de las restricciones aplicables al intercambio de datos. Los conjuntos de datos originales de gran tamaño o de carácter sensible pueden requerir un procedimiento de acceso en lugar de su inclusión en el repositorio.

2.4. Nombres y rutas

Se recomienda utilizar nombres de archivo descriptivos y estables, como `data_quality.qmd` o `missingness_profile.qmd`. Los prefijos numéricos pueden ayudar cuando existe una secuencia significativa, pero no deben sugerir que los cuadernos requieren una sesión interactiva compartida.

Prefiera rutas relativas al proyecto en lugar de rutas absolutas específicas de una máquina. Un proyecto no debe depender del directorio personal de un estudiante en particular ni de archivos colocados manualmente fuera de la estructura documentada del repositorio. En R, herramientas como `here` pueden ayudar a construir rutas a partir de una raíz de proyecto consistente, siempre que dicha raíz esté configurada y se comprenda cómo se determina.

3. Cuadernos computacionales

3.1. El papel de los cuadernos Quarto

Un documento Quarto `.qmd` combina texto, código R ejecutable y resultados computacionales. En esta guía, un *cuaderno* es un documento analítico ejecutable cuya responsabilidad principal es realizar y explicar una tarea computacional coherente.

Un cuaderno es más que una colección de instrucciones de R. Debe indicar qué busca establecer, hacer explícitos sus datos de entrada, documentar su procedimiento, presentar sus resultados y explicar qué implican esos resultados para la investigación.

3.2. Programación literaria y el "cómo" computacional

El uso de cuadernos computacionales se basa en la filosofía de la *programación literaria*: las instrucciones ejecutables van acompañadas de explicaciones escritas para lectores humanos. En este marco, un cuaderno es una descripción técnica de *cómo* se llevó a cabo una tarea analítica, no un segundo informe científico.

Su texto debe explicar los datos de entrada, las operaciones, los parámetros, los resultados y las decisiones de implementación pertinentes. Puede ofrecer un contexto analítico conciso, pero los argumentos extensos sobre la idoneidad científica de un método corresponden al informe de investigación. Por ejemplo, un cuaderno debe identificar la regla precisa aplicada a los datos faltantes y mostrar sus consecuencias; el informe debe justificar esa regla en relación con la pregunta de investigación y la evidencia disponible.

La documentación propia de la programación literaria mejora la inteligibilidad y la transparencia computacional. Por sí sola, no garantiza la reproducibilidad: el acceso a los datos, las versiones de los paquetes, las condiciones de ejecución y las dependencias también deben abordarse en el ámbito del repositorio.

3.3. Una responsabilidad analítica por cuaderno

Un principio útil, inspirado en la filosofía Unix, es *hacer una cosa y hacerla bien*. Aplicado a los cuadernos, esto significa que cada documento debe tener un propósito analítico reconocible. Un cuaderno podría examinar la estructura de un conjunto de datos, evaluar su calidad o construir un conjunto de datos preparado. Cada tarea puede implicar varias funciones y cálculos.

La unidad adecuada de modularidad es una *tarea analítica coherente*, no una instrucción individual de R. Crear un cuaderno separado para cada cálculo menor introduciría una fragmentación innecesaria.

Un cuaderno puede reutilizarse o revisarse durante varios periodos de presentación de informes. A la inversa, un solo informe puede basarse en varios cuadernos. Por tanto, los límites entre cuadernos no deben estar determinados únicamente por las fechas de entrega de los informes.

3.4. Una estructura estándar para los cuadernos

Una estructura interna consistente facilita la revisión y reproducción de los cuadernos:

Elemento	Pregunta que aborda
Objetivo	¿Qué busca establecer o producir este cuaderno?
Entradas	¿Qué datos, parámetros y dependencias se requieren?
Procedimiento	¿Qué operaciones se realizan y en qué orden?
Salidas	¿Qué tablas, figuras, conjuntos de datos o resultados se producen?
Interpretación	¿Qué muestran los resultados sobre esta tarea computacional y qué comprobaciones o limitaciones son relevantes para su uso?

Esta es una plantilla conceptual, no un requisito de utilizar exactamente cinco encabezados en cada documento. La explicación debe ser proporcional a la complejidad y la importancia de la tarea.

3.5. Ejecución independiente y dependencias explícitas

Una regla fundamental es que *cada cuaderno debe ejecutarse en una sesión nueva de R*, sin depender de objetos que hayan quedado en memoria de un trabajo interactivo previo. Puede depender de archivos producidos en otro paso, pero esas dependencias deben estar documentadas y ser reproducibles.

Por ejemplo, un cuaderno debe cargar su propio conjunto de datos de entrada en lugar de suponer que ya existe un objeto llamado `data` en el entorno global. Si se requiere un conjunto de datos procesado, el proyecto debe explicar cómo se crea.

Este principio ayuda a prevenir un fallo común de los cuadernos: un documento que parece funcionar de manera interactiva, pero falla cuando se ejecuta de principio a fin. Una práctica útil de validación consiste en renderizar el cuaderno en una sesión limpia e inspeccionar los resultados y errores obtenidos.

3.6. Transparencia computacional y reproducibilidad

La *transparencia computacional* significa que el lector puede comprender qué cálculos se realizaron. La *reproducibilidad computacional* exige, además, que esos cálculos puedan ejecutarse de nuevo bajo condiciones documentadas.

El código legible y el texto explicativo favorecen la transparencia. Las dependencias explícitas, los datos de entrada accesibles, la aleatoriedad controlada y la ejecución en sesiones limpias favorecen la reproducibilidad. Ninguna debe tratarse como sustituto de la otra.

4. Informes de investigación y artículos científicos

4.1. Los informes de investigación como documentación metodológica

El público principal de un *informe de investigación* es un investigador que necesita comprender, evaluar, incorporarse a la investigación o continuarla. Su propósito es preservar el conocimiento metodológico acumulado por el proyecto, en lugar de anunciar una contribución seleccionada a la literatura científica.

Un informe debe explicar *qué* se investigó y *por qué* se tomaron las decisiones principales. Debe documentar las preguntas de investigación, los datos disponibles, el diseño metodológico, las alternativas consideradas cuando sean pertinentes, los resultados obtenidos, las limitaciones, las preguntas pendientes y los posibles pasos siguientes. Debe ser lo suficientemente detallado como para facilitar la continuidad de la investigación, sin convertirse en un diario cronológico exhaustivo de cada acción.

Por ejemplo, un informe puede explicar por qué se excluyeron las observaciones con valores faltantes, qué alternativas se consideraron y cómo afecta esa decisión a la interpretación de los resultados. Un cuaderno de apoyo puede mostrar exactamente cómo se cuantificaron los datos faltantes, qué filas se excluyeron y cómo se verificó el conjunto de datos resultante.

Este papel es especialmente valioso cuando sucesivos grupos de estudiantes o colaboradores contribuyen al mismo proyecto. El informe debe reducir el esfuerzo necesario para que un

nuevo investigador comprenda el estado actual de la investigación y participe de manera significativa.

4.2. Los artículos científicos como comunicación de contribuciones a la investigación

Un *artículo científico* se dirige a un público disciplinar más amplio. Su propósito es identificar, contextualizar y fundamentar una contribución al conocimiento científico. Destaca la literatura pertinente, la pregunta que se responde, la novedad o importancia de los hallazgos, la evidencia que respalda las afirmaciones y las implicaciones y limitaciones de la contribución.

Por tanto, un artículo se organiza en torno a una *contribución científica*, mientras que un informe de investigación se organiza en torno a la *investigación*. Un proyecto puede documentar experimentos fallidos, alternativas abandonadas y preguntas abiertas que son útiles para su continuidad, pero secundarias para una publicación centrada en una contribución específica. Un proyecto puede dar lugar a varios artículos o a ninguna publicación.

El artículo debe describir sus métodos con suficiente detalle para permitir el escrutinio científico y, cuando corresponda, la reproducibilidad. No puede omitirse información esencial simplemente porque exista un informe del proyecto. Sin embargo, el informe puede preservar una descripción más completa de las decisiones y los antecedentes necesarios para continuar la investigación en su conjunto. El código, los datos y los informes de apoyo pueden ponerse a disposición como materiales suplementarios cuando sea apropiado y esté permitido.

4.3. Responsabilidades complementarias

Las responsabilidades complementarias de los cuadernos computacionales, los informes y los artículos pueden resumirse de la siguiente manera:

Aspecto	Informe	Cuaderno	Artículo científico
Público principal	Colaboradores actuales y futuros	Personas que ejecutan o revisan los cálculos	Comunidad de investigación de la disciplina
Pregunta de investigación	Explicar las preguntas del proyecto y su evolución	Enunciar la tarea analítica que se implementa	Centrarse en la pregunta que motiva la contribución
Decisiones metodológicas	Explicar y justificar las decisiones y las alternativas pertinentes	Registrar las decisiones precisas implementadas	Describir y justificar las decisiones esenciales para evaluar las afirmaciones

Aspecto	Informe	Cuaderno	Artículo científico
Resultados	Preservar los hallazgos pertinentes, incluidos los no concluyentes	Producir resultados detallados y comprobaciones	Seleccionar y presentar la evidencia que sustenta la contribución
Interpretación	Explicar las implicaciones para la continuidad del proyecto	Interpretar los resultados y diagnósticos específicos de la tarea	Situar los hallazgos en el contexto del conocimiento científico
Reproducibilidad	Vincular las decisiones y los hallazgos con los materiales de apoyo	Proporcionar evidencia computacional ejecutable	Proporcionar suficiente detalle metodológico y acceso a la evidencia de apoyo según los requisitos aplicables

La división es de *énfasis, público y propósito*, no una separación absoluta de los temas tratados. En particular, la justificación metodológica es central en el informe, pero un artículo científico debe poder evaluarse de manera independiente.

4.4. Relación con los hitos de presentación de informes

Los informes pueden organizarse en torno a fechas de entrega, revisiones del proyecto o etapas del curso, pero su valor duradero reside en preservar una descripción comprensible de la investigación. Los cuadernos computacionales no tienen que seguir el mismo calendario. Un informe puede sintetizar varios cuadernos, y un cuaderno puede servir de apoyo a varios informes o artículos.

Para preservar la trazabilidad, los informes y artículos deben identificar el cuaderno o la fuente reproducible correspondiente a los principales hallazgos computacionales. Cuando sea viable, las tablas y figuras deben generarse a partir de los mismos cálculos subyacentes, en lugar de transcribirse manualmente.

5. Flujos de trabajo modulares y automatizados

5.1. Modularidad analítica y modularidad del software

Deben distinguirse dos formas de modularidad:

- **Modularidad analítica:** divide la investigación en tareas coherentes, cada una representada por un cuaderno u otro componente analítico bien definido.
- **Modularidad del software:** separa la lógica computacional reutilizable en funciones y módulos que pueden invocarse desde varios lugares.

La modularidad analítica puede aprenderse y practicarse antes que la modularidad del software. Es razonable que un proyecto pequeño contenga la mayor parte de su código directamente en los cuadernos. Los cálculos repetidos o complejos pueden extraerse posteriormente y convertirse en funciones.

5.2. Funciones reutilizables de R y `src/`

A medida que crece un análisis, los cálculos o las transformaciones repetidos pueden trasladarse a funciones de R almacenadas en `src/` y presentarse como un paquete. El cuaderno se centra entonces en la tarea analítica y su interpretación, mientras que la función encapsula una operación reutilizable.

Por ejemplo, un cálculo sencillo de la proporción de valores faltantes podría definirse así:

```
proportion_missing <- function(x) {
  mean(is.na(x))
}

proportion_missing(c(2, NA, 4, NA))
```

```
[1] 0.5
```

Este ejemplo ilustra la separación de responsabilidades, no una exigencia de convertir cada operación de una línea en una función. Extraer código vale la pena cuando mejora la claridad, la consistencia, las pruebas o la reutilización.

5.3. Scripts ejecutables y `scripts/`

Un directorio `scripts/` puede contener programas que coordinan tareas: obtener datos, generar conjuntos de datos derivados, validar resultados o renderizar una secuencia de documentos. Según esta convención, `src/` contiene componentes computacionales reutilizables, mientras que `scripts/` contiene puntos de entrada que ejecutan un flujo de trabajo.

Esta distinción es útil, pero no universal. Algunos proyectos utilizan otras convenciones de nombres o adoptan un gestor de flujos de trabajo. El requisito importante es que cada componente tenga una responsabilidad clara y entradas y salidas documentadas.

5.4. Del análisis interactivo a un flujo de trabajo automatizado

Un proyecto puede desarrollarse de forma progresiva:

Nivel	Componentes principales	Capacidad principal
Análisis reproducible	Datos, cuadernos, informes	Volver a ejecutar análisis documentados
Computación modular	Incorporar funciones reutilizables de R	Reducir la duplicación y aislar la lógica computacional
Flujo de trabajo automatizado	Incorporar scripts de coordinación o herramientas de flujo de trabajo	Ejecutar sistemáticamente operaciones vinculadas

Estos niveles representan una sofisticación técnica creciente, no etapas obligatorias. Un proyecto de investigación pequeño puede ser plenamente adecuado en el primer nivel.

Un flujo de trabajo automatizado debe hacer explícitas las dependencias: qué entradas se requieren, qué proceso produce cada salida y qué debe volver a ejecutarse cuando cambia una entrada. En proyectos complejos, las herramientas de flujo de trabajo pueden automatizar el seguimiento de las dependencias; en proyectos más pequeños, pueden bastar instrucciones claras y unos cuantos scripts bien diseñados.

5.5. Comprobaciones de reproducibilidad

Antes de considerar reproducible un análisis, verifique que:

1. Los datos de entrada originales pueden identificarse y obtenerse.
2. El proyecto explica cómo instalar o restaurar el entorno de software requerido.
3. Los cuadernos se ejecutan desde una sesión limpia en un orden documentado, o de forma independiente cuando así esté previsto.
4. Las dependencias entre cuadernos, scripts y conjuntos de datos generados son explícitas.
5. Los resultados importantes pueden regenerarse sin modificaciones manuales no documentadas.
6. Los informes concuerdan con los resultados computacionales que los sustentan.
7. Las decisiones metodológicas y las limitaciones se registran en una ubicación adecuada.

Estas comprobaciones conectan las dimensiones computacional y metodológica de la reproducibilidad. Una renderización exitosa constituye evidencia necesaria de reproducibilidad computacional, pero no establece por sí sola que el análisis haya sido metodológicamente apropiado.

6. Uso educativo del marco

6.1. Responsabilidades docentes y competencias previstas

El marco está diseñado para orientar a los docentes en el diseño y la supervisión de proyectos de ciencia de datos orientados a la investigación. Sus convenciones no son meras reglas de gestión de archivos: cada una crea oportunidades para que los estudiantes practiquen aspectos del trabajo de investigación.

Práctica	Competencia o hábito previsto
Clonar y mantener un repositorio compartido	Control de versiones, colaboración y trazabilidad
Restaurar un entorno de `renv`	Comprensión y gestión de las dependencias computacionales
Separar los datos originales de los procesados	Procedencia de los datos y preparación disciplinada
Desarrollar cuadernos centrados en tareas	Documentación computacional y modularidad analítica
Ejecutar cuadernos en sesiones limpias	Verificación de la reproducibilidad computacional
Preparar informes de investigación	Razonamiento metodológico, justificación y continuidad de la investigación
Elaborar un artículo científico cuando se justifique	Contextualización, fundamentación y comunicación de una contribución a la investigación

Estos son *resultados de aprendizaje previstos*, no afirmaciones de que las prácticas produzcan o demuestren automáticamente una competencia. Los docentes deben determinar qué evidencia del aprendizaje estudiantil es apropiada en el contexto de su curso. Un estudiante puede comenzar a practicar estos hábitos siguiendo una plantilla de proyecto proporcionada antes de comprender todos los principios subyacentes; el docente debe comprender por qué son importantes estas convenciones.

6.2. El marco y su implementación en el aula

La arquitectura del repositorio describe cómo se organizan los materiales de investigación; la metodología de investigación describe cómo procede la investigación; y el diseño instruccional describe cómo aprenden los estudiantes a participar en ese trabajo. Estas estructuras no tienen que corresponderse una a una.

Por este motivo, esta guía no prescribe etapas del curso, rúbricas de evaluación ni instrucciones paso a paso para estudiantes. Estos elementos pueden desarrollarse por separado, en función de la preparación de los estudiantes y de los requisitos de un curso concreto. Del mismo modo, publicar un trabajo educativo sobre el marco requeriría una argumentación y evidencia específicas acerca de su implementación y su contribución educativa.

7. Principios finales

Un proyecto reproducible de ciencia de datos se beneficia de una separación de responsabilidades:

- Los *cuadernos computacionales* explican *cómo* se ejecutan tareas analíticas coherentes, siguiendo la filosofía de la programación literaria.
- Los *informes de investigación* preservan *qué* se investigó y *por qué* se tomaron decisiones metodológicas importantes, lo que permite la evaluación y la continuidad de la investigación.
- Los *artículos científicos* comunican hallazgos seleccionados, establecen su contexto científico y aportan evidencia y detalle metodológico suficientes para examinar las contribuciones que afirman realizar.
- Las *funciones reutilizables* implementan operaciones computacionales que conviene compartir.
- Los *scripts y las herramientas de flujo de trabajo* coordinan una ejecución repetible cuando el proyecto requiere automatización.
- El *repositorio* conecta los materiales de investigación, las entradas, las dependencias y las salidas en un conjunto trazable y reproducible.

El objetivo no es imponer una arquitectura de software compleja ni un flujo de publicación a todas las investigaciones. Es preservar el conocimiento metodológico, hacer reproducibles los cálculos y favorecer una comunicación científica responsable, introduciendo estructura adicional solo cuando mejore la claridad, la fiabilidad, la colaboración o la facilidad de mantenimiento.